Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Домашняя работа
по дисциплине
«Методы машинного обучения»

Выполнил:
студент группы ИУ5-22М
Смирнов А. И.

Москва — 2019 г.

1. Задание

Требуется выполнить следующие действия [1]:

1. Поиск и выбор набора данных для построения моделей машинного обучения. На основе выбранного набора данных студент должен построить модели машинного обучения для решения или задачи классификации, или задачи регрессии.
2. Проведение разведочного анализа данных. Построение графиков, необходимых для понимания структуры данных. Анализ и заполнение пропусков в данных.
3. Выбор признаков, подходящих для построения моделей. Кодирование категориальных признаков. Масштабирование данных. Формирование вспомогательных признаков, улучшающих качество моделей.
4. Проведение корреляционного анализа данных. Формирование промежуточных выводов о возможности построения моделей машинного обучения. В зависимости от набора данных, порядок выполнения пунктов 2, 3, 4 может быть изменен.
5. Выбор метрик для последующей оценки качества моделей. Необходимо выбрать не менее двух метрик и обосновать выбор.
6. Выбор наиболее подходящих моделей для решения задачи классификации или регрессии. Необходимо использовать не менее трех моделей, хотя бы одна из которых должна быть ансамблевой.
7. Формирование обучающей и тестовой выборок на основе исходного набора данных.
8. Построение базового решения (baseline) для выбранных моделей без подбора гиперпараметров. Производится обучение моделей на основе обучающей выборки и оценка качества моделей на основе тестовой выборки.
9. Подбор гиперпараметров для выбранных моделей. Рекомендуется подбирать не более 1-2 гиперпараметров. Рекомендуется использовать методы кросс-валидации. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы.
10. Повторение пункта 8 для найденных оптимальных значений гиперпараметров. Сравнение качества полученных моделей с качеством baseline-моделей.
11. Формирование выводов о качестве построенных моделей на основе выбранных метрик.

2. Ход выполнения работы

2.1. Выбор набора данных

В качестве набора данных используются метрологические данные с метеостанции HI-SEAS (Hawaii Space Exploration Analog and Simulation) за четыре месяца (с сентября по декабрь 2016 года) и использовался в соревновании Space Apps Moscow 2017 в категории «You are my Sunshine» для построения приложения для предсказания мощности солнечного излучения и планирования работы исследовательской станции [2,3]. Данный набор данных доступен по следующему адресу: https://www.kaggle.com/dronio/SolarEnergy.

2.1.1. Текстовое описание набора данных

Выбранный набор данных состоит из одного файла SolarPrediction.csv, содержащего все данные датасета. Данный файл содержит следующие колонки:

- UNIXTime — временная метка измерения в формате UNIX;
- Data — дата измерения;
- Time — время измерения (в местной временной зоне);

- Radiation — солнечное излучение (Вт/м^2);
- Temperature — температура (°F);
- Pressure — атмосферное давление (дюймов ртутного столба);
- Humidity — относительная влажность (%);
- WindDirection(Degrees) — направление ветра (°);
- Speed — скорость ветра (миль/ч);
- TimeSunRise — время восхода (в местной временной зоне);
- TimeSunSet — время заката (в местной временной зоне).

2.1.2. Постановка задачи и предварительный анализ набора данных

Очевидно, что данный набор данных предполагает задачу регрессии, а именно предсказание колонки Radiation — мощности солнечного излучения. При этом:

- Колонка UNIXTime сама по себе довольно бесполезна, так как просто монотонно растёт с течением времени, не давая какую-либо информацию для модели машинного обучения. Вместе с тем, колонка Time может быть довольно интересной, особенно вместе с колонками TimeSunRise и TimeSunSet, так как вместе они показывают положение солнца на небе и точно задают возможный максимум солнечной энергии.
- Колонка Data могла бы быть полезна, если бы данные были за больший промежуток времени (например, несколько лет), и отражала бы сезонность солнечного излучения. К сожалению в нашем случае она практически полностью бесполезна.
- Остальные колоки предоставляют данные, которые теоретически могут показывать, сколько именно солнечной энергии доходит до поверхности, то есть по факту по ним необходимо предсказывать облачность.

2.2. Проведение разведочного анализа данных

Подключим все необходимые библиотеки:

[1]:
```
from datetime import datetime
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

Настроим отображение графиков [4, 5]:

[2]:
```
# Enable inline plots
%matplotlib inline

# Set plot style
sns.set(style="ticks")

# Set plots formats to save high resolution PNG
from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")
```

Зададим ширину текстового представления данных, чтобы в дальнейшем текст в отчёте влезал на A4 [6]:

[3]:
```
pd.set_option("display.width", 70)
```

2.2.1. Предварительная подготовка данных

Загрузим описанный выше набор данных:

[4]:
```
data = pd.read_csv("./SolarPrediction.csv")
```

Преобразуем временные колонки в соответствующий временной формат:

[5]:
```
data["Time"] = (pd
                .to_datetime(data["UNIXTime"], unit="s", utc=True)
                .dt.tz_convert("Pacific/Honolulu")).dt.time

data["TimeSunRise"] = (pd
                .to_datetime(data["TimeSunRise"],
                             infer_datetime_format=True)
                .dt.time)

data["TimeSunSet"] = (pd
                .to_datetime(data["TimeSunSet"],
                             infer_datetime_format=True)
                .dt.time)

data = data.rename({"WindDirection(Degrees)": "WindDirection"},
                   axis=1)
```

Проверим полученные типы:

[6]:
```
data.dtypes
```

[6]:
```
UNIXTime          int64
Data             object
Time             object
Radiation       float64
Temperature       int64
Pressure        float64
Humidity          int64
WindDirection   float64
Speed           float64
TimeSunRise      object
TimeSunSet       object
dtype: object
```

Посмотрим на данные в данном наборе данных:

[7]:
```
data.head()
```

[7]:

	UNIXTime	Data	Time	Radiation	Temperature	Pressure	Humidity	WindDirection	Speed
0	1475229326	9/29/2016 12:00:00 AM	23:55:26	1.21	48	30.46	59	177.39	5.62
1	1475229023	9/29/2016 12:00:00 AM	23:50:23	1.21					
2	1475228726	9/29/2016 12:00:00 AM	23:45:26	1.23					
3	1475228421	9/29/2016 12:00:00 AM	23:40:21	1.21					
4	1475228124	9/29/2016 12:00:00 AM	23:35:24	1.17					

```
1         48    30.46        58       176.78   3.37
2         48    30.46        57       158.75   3.37
3         48    30.46        60       137.71   3.37
4         48    30.46        62       104.95   5.62

  TimeSunRise TimeSunSet
0    06:13:00   18:13:00
1    06:13:00   18:13:00
2    06:13:00   18:13:00
3    06:13:00   18:13:00
4    06:13:00   18:13:00
```

Очевидно, что все эти временные характеристики в таком виде нам не особо интересны. Преобразуем все нечисловые столбцы в числовые. Для преобразования времени в секунды используем следующий метод [7]:

[8]:
```
def time_to_second(t):
    return ((datetime.combine(datetime.min, t) - datetime.min)
            .total_seconds())
```

[9]:
```
df = data.copy()

timeInSeconds = df["Time"].map(time_to_second)

sunrise = df["TimeSunRise"].map(time_to_second)
sunset = df["TimeSunSet"].map(time_to_second)
df["DayPart"] = (timeInSeconds - sunrise) / (sunset - sunrise)

df = df.drop(["UNIXTime", "Data", "Time",
              "TimeSunRise", "TimeSunSet"], axis=1)

df.head()
```

[9]:
```
   Radiation  Temperature  Pressure  Humidity  WindDirection  Speed  \
0       1.21           48     30.46        59         177.39   5.62
1       1.21           48     30.46        58         176.78   3.37
2       1.23           48     30.46        57         158.75   3.37
3       1.21           48     30.46        60         137.71   3.37
4       1.17           48     30.46        62         104.95   5.62

    DayPart
0  1.475602
1  1.468588
2  1.461713
3  1.454653
4  1.447778
```

[10]:
```
df.dtypes
```

[10]:
```
Radiation       float64
Temperature       int64
Pressure        float64
```

```
Humidity          int64
WindDirection    float64
Speed            float64
DayPart          float64
dtype: object
```

С такими данными уже можно работать. Проверим размер набора данных:

[11]:
```
df.shape
```

[11]:
```
(32686, 7)
```

Проверим основные статистические характеристики набора данных:

[12]:
```
df.describe()
```

[12]:
```
          Radiation   Temperature      Pressure      Humidity  \
count  32686.000000  32686.000000  32686.000000  32686.000000
mean     207.124697     51.103255     30.422879     75.016307
std      315.916387      6.201157      0.054673     25.990219
min        1.110000     34.000000     30.190000      8.000000
25%        1.230000     46.000000     30.400000     56.000000
50%        2.660000     50.000000     30.430000     85.000000
75%      354.235000     55.000000     30.460000     97.000000
max     1601.260000     71.000000     30.560000    103.000000

       WindDirection         Speed       DayPart
count   32686.000000  32686.000000  32686.000000
mean      143.489821      6.243869      0.482959
std        83.167500      3.490474      0.602432
min         0.090000      0.000000     -0.634602
25%        82.227500      3.370000     -0.040139
50%       147.700000      5.620000      0.484332
75%       179.310000      7.870000      1.006038
max       359.950000     40.500000      1.566061
```

Проверим наличие пропусков в данных:

[13]:
```
df.isnull().sum()
```

[13]:
```
Radiation        0
Temperature      0
Pressure         0
Humidity         0
WindDirection    0
Speed            0
DayPart          0
dtype: int64
```

2.2.2. Визуальное исследование датасета

Оценим распределение целевого признака — мощности солнечного излучения:

[14]:
```
sns.distplot(df["Radiation"]);
```

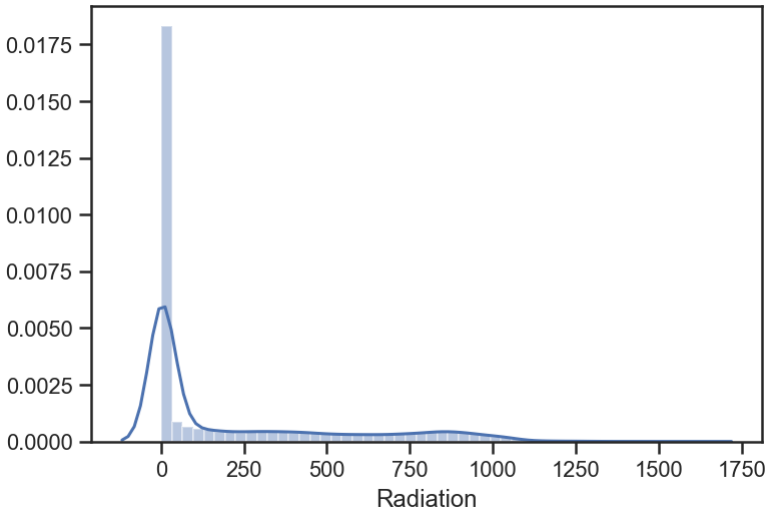

Видно, что имеется большой перевес в пользу практически нулевого излучения. Оценим, насколько мощность солнечного излучения зависит от наличия солнца на небе:

[15]:
```
sns.jointplot(x="DayPart", y="Radiation", data=df, kind="hex");
```

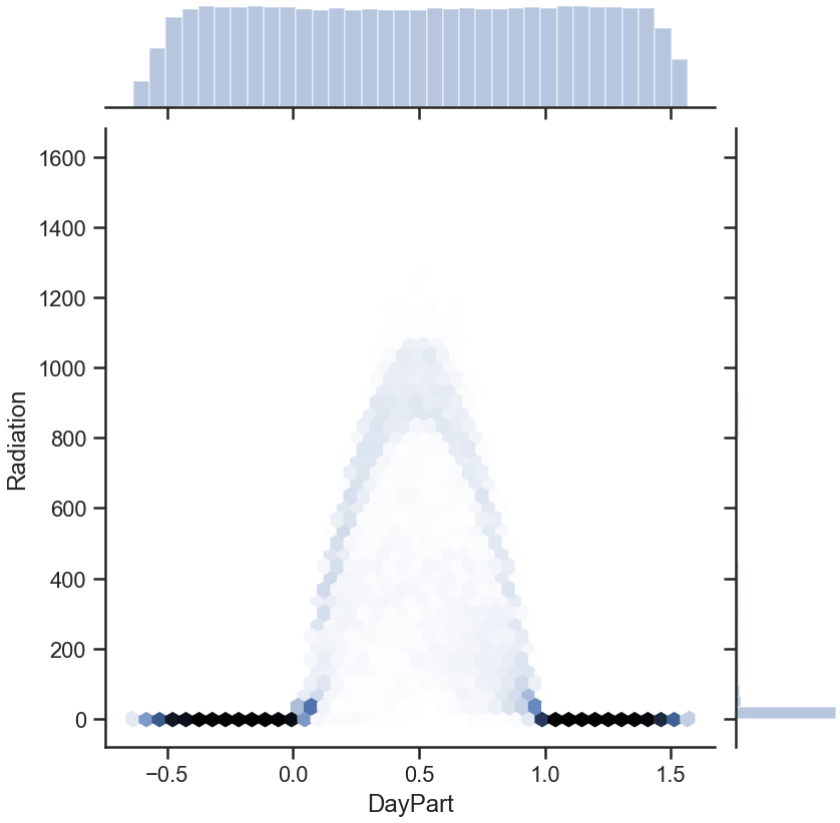

Видно, что если солнца нет на небе, то мощность солнечного излучения стремится к нулю. Посмотрим на распределение мощности излучения в течение дня:

[16]:
```
dfd = df[(df["DayPart"] >= 0) & (df["DayPart"] <= 1)]
sns.distplot(dfd["Radiation"]);
```

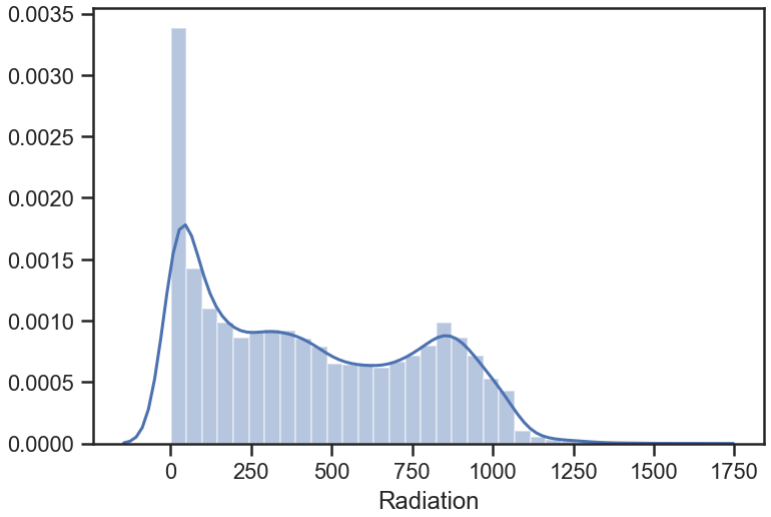

Теперь оценить влияние времени дня на мощность солнечного излучения будет заметно проще:

[17]:
```
sns.jointplot(x="DayPart", y="Radiation", data=dfd, kind="hex");
```

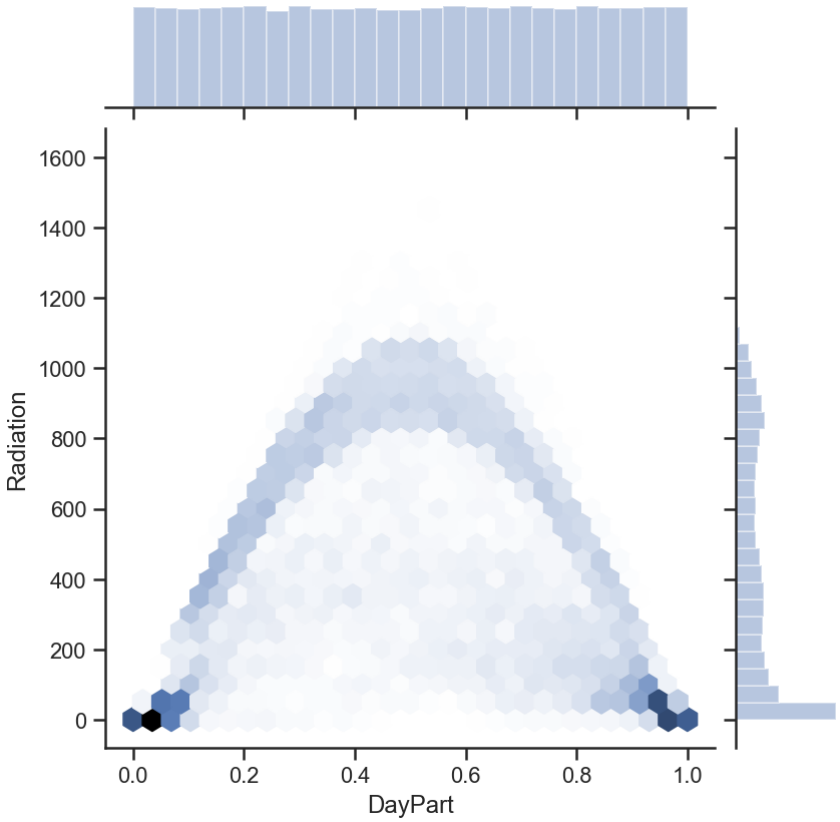

Посмотрим также на зависимость мощности солнечного излучения от температуры:

[18]:
```
sns.jointplot(x="Temperature", y="Radiation", data=dfd, kind="kde");
```

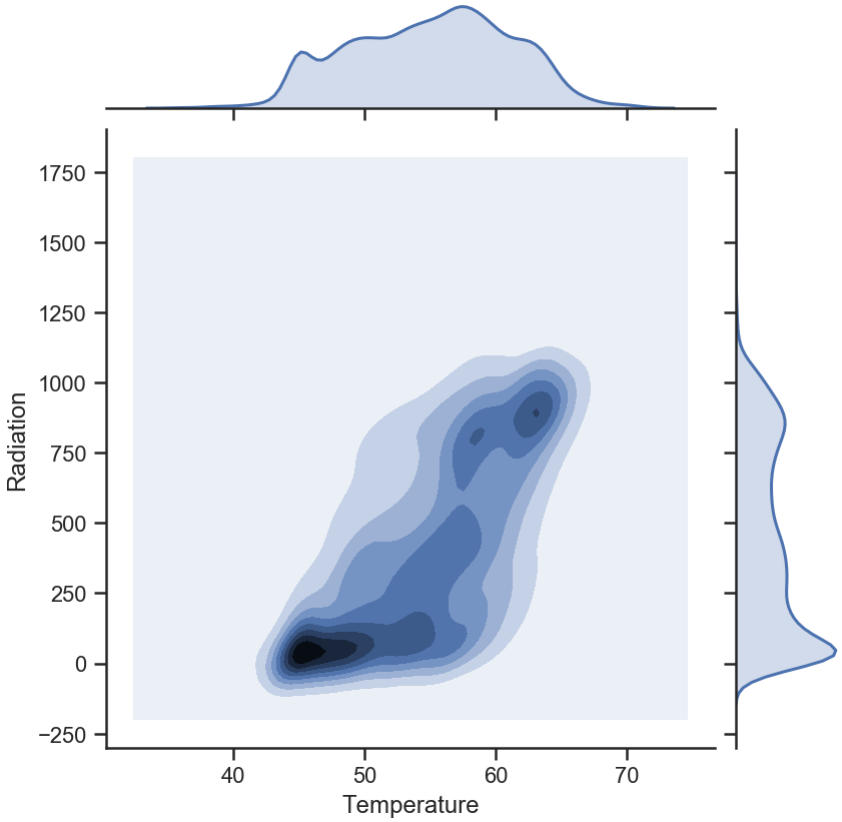

Видно, что некоторая зависимость определённо есть, но не настолько большая, насколько хотелось бы. Возможно на большей выборке эта зависимость стала бы ещё менее заметной.

Построим парные диаграммы по всем показателям по исходному набору данных:

[19]:
```
sns.pairplot(df, plot_kws=dict(linewidth=0));
```

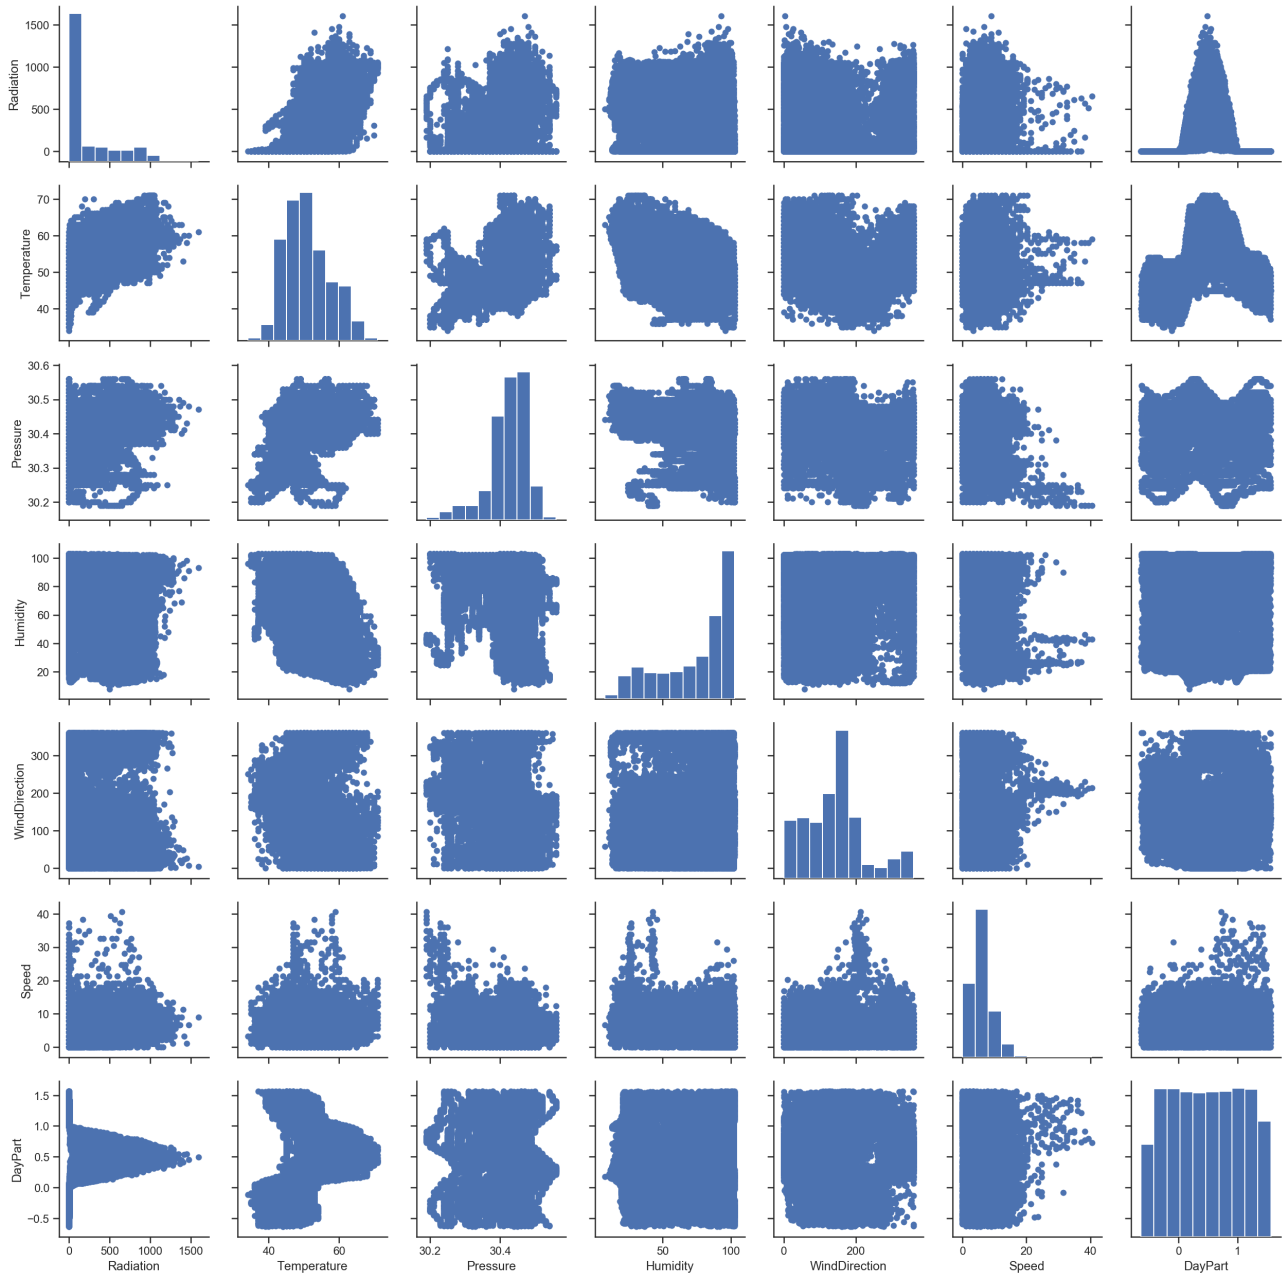

Видно, что зависимости между колонками весьма сложные и в большинстве своём нелинейные. Какого-то показателя, точно определяющего мощность излучения, не наблюдается. Вместе с тем чётко видно, что время суток ограничивает мощность излучения сверху, что вполне может быть полезно для модели машинного обучения.

2.2.3. Корреляционный анализ

Построим корреляционную матрицу по всему набору данных:

[20]:
```
df.corr()
```

[20]:
```
                Radiation  Temperature  Pressure  Humidity  \
Radiation        1.000000     0.734955  0.119016 -0.226171
Temperature      0.734955     1.000000  0.311173 -0.285055
Pressure         0.119016     0.311173  1.000000 -0.223973
```

```
Humidity       -0.226171    -0.285055 -0.223973  1.000000
WindDirection  -0.230324    -0.259421 -0.229010 -0.001833
Speed           0.073627    -0.031458 -0.083639 -0.211624
DayPart         0.005980     0.198520  0.094403  0.075513

               WindDirection     Speed   DayPart
Radiation          -0.230324  0.073627  0.005980
Temperature        -0.259421 -0.031458  0.198520
Pressure           -0.229010 -0.083639  0.094403
Humidity           -0.001833 -0.211624  0.075513
WindDirection       1.000000  0.073092 -0.078130
Speed               0.073092  1.000000 -0.056095
DayPart            -0.078130 -0.056095  1.000000
```

Визуализируем корреляционную матрицу с помощью тепловой карты:

[21]:
```
sns.heatmap(df.corr(), annot=True, fmt=".2f");
```

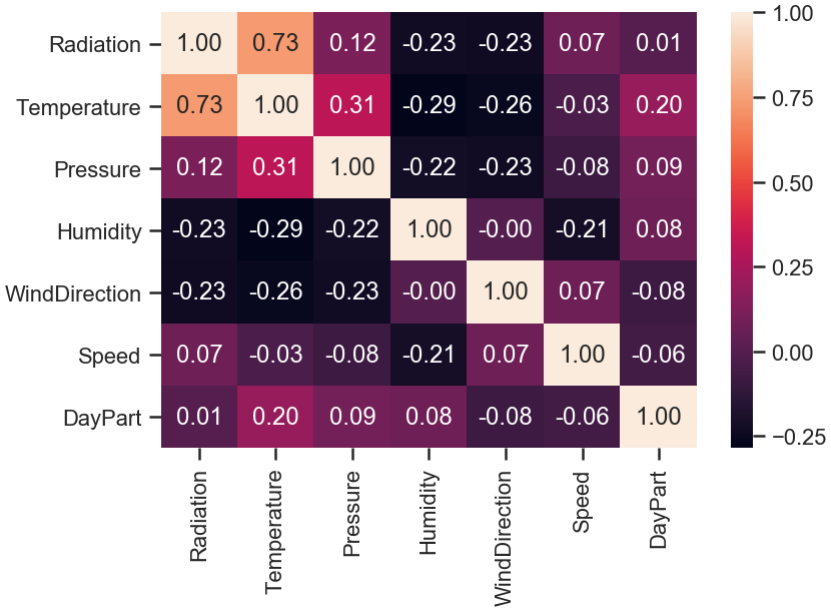

Видно, что мощность солнечного излучения заметно коррелирует с температурой, что было показано выше с помощью парного графика. Остальные признаки коррелируют друг с другом довольно слабо. Построению моделей машинного обучения ничего не мешает, но насколько хорошо они будут работать — вопрос открытый.

2.3. Подготовка данных для обучения моделей

Разделим данные на целевой столбец и признаки:

[22]:
```
X = df.drop("Radiation", axis=1)
y = df["Radiation"]
```

[23]:
```
print(X.head(), "\n")
print(y.head())
```

	Temperature	Pressure	Humidity	WindDirection	Speed	DayPart
0	48	30.46	59	177.39	5.62	1.475602
1	48	30.46	58	176.78	3.37	1.468588
2	48	30.46	57	158.75	3.37	1.461713
3	48	30.46	60	137.71	3.37	1.454653
4	48	30.46	62	104.95	5.62	1.447778

```
0    1.21
1    1.21
2    1.23
3    1.21
4    1.17
Name: Radiation, dtype: float64
```

[24]:
```
print(X.shape)
print(y.shape)
```

```
(32686, 6)
(32686,)
```

Предобработаем данные, чтобы методы работали лучше:

[25]:
```
from sklearn.preprocessing import StandardScaler

columns = X.columns
scaler = StandardScaler()
X = scaler.fit_transform(X)
pd.DataFrame(X, columns=columns).describe()
```

[25]:

	Temperature	Pressure	Humidity	WindDirection	Speed	DayPart
count	3.268600e+04	3.268600e+04	3.268600e+04	3.268600e+04	3.268600e+04	3.268600e+04
mean	5.565041e-16	2.904952e-14	1.391260e-17	6.956302e-17	-9.738822e-17	5.217226e-18
std	1.000015e+00	1.000015e+00	1.000015e+00	1.000015e+00	1.000015e+00	1.000015e+00
min	-2.758117e+00	-4.259540e+00	-2.578560e+00	-1.724255e+00	-1.788859e+00	-1.855112e+00
25%	-8.229646e-01	-4.184734e-01	-7.316829e-01	-7.366250e-01	-8.233591e-01	-8.683240e-01
50%	-1.779139e-01	1.302504e-01	3.841386e-01	5.062367e-02	-1.787376e-01	2.279483e-03
75%	6.283995e-01	6.789742e-01	8.458578e-01	4.307058e-01	4.658840e-01	8.682924e-01
max	3.208603e+00	2.508053e+00	1.076717e+00	2.602741e+00	9.814329e+00	1.797910e+00

2.4. Выбор метрик

Напишем функцию, которая считает метрики построенной модели:

[26]:
```
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import median_absolute_error
from sklearn.metrics import r2_score

def test_model(model):
    print("mean_absolute_error:",
          mean_absolute_error(y_test, model.predict(X_test)))
    print("median_absolute_error:",
          median_absolute_error(y_test, model.predict(X_test)))
    print("r2_score:",
          r2_score(y_test, model.predict(X_test)))
```

Очевидно, что все эти метрики подходят для задачи регрессии. При этом средняя абсолютная ошибка (mean_absolute_error) будет показывать, насколько в среднем мы ошибаемся, медианная абсолютная ошибка (median_absolute_error) — насколько мы ошибаемся на половине выборки, а коэффициент детерминации R^2 (r2_score) хорош тем, что он показывает качество модели машинного обучения в задачи регрессии без сравнения с другими моделями.

2.5. Выбор моделей

В качестве моделей машинного обучения выберем хорошо показавшие себя в лабораторных работах модели:

- Метод k ближайших соседей (KNeighborsRegressor)
- Дерево решений (DecisionTreeRegressor)
- Случайный лес (RandomForestRegressor)

[27]:
```
from sklearn.neighbors import KNeighborsRegressor
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import RandomForestRegressor
```

2.6. Формирование обучающей и тестовой выборок

Разделим выборку на обучающую и тестовую:

[28]:
```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y,
                                   test_size=0.25, random_state=346705925)
```

[29]:
```
print(X_train.shape)
print(X_test.shape)
print(y_train.shape)
print(y_test.shape)
```

```
(24514, 6)
(8172, 6)
(24514,)
(8172,)
```

2.7. Построение базового решения

2.8. Метод k ближайших соседей

Попробуем метод k ближайших соседей с гиперпараметром $k = 5$:

[30]:
```
knn_5 = KNeighborsRegressor(n_neighbors=5)
knn_5.fit(X_train, y_train)
```

[30]:
```
KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
                    metric_params=None, n_jobs=None, n_neighbors=5, p=2,
                    weights='uniform')
```

Проверим метрики построенной модели:

[31]:
```
test_model(knn_5)
```

```
mean_absolute_error: 55.39857905041605
median_absolute_error: 4.017000000000004
r2_score: 0.8677873476991447
```

Видно, что данный метод даже без настройки гиперпараметров уже показывает очень неплохой результат.

2.9. Дерево решений

Попробуем дерево решений с неограниченной глубиной дерева:

[32]:
```
dt_none = DecisionTreeRegressor(max_depth=None)
dt_none.fit(X_train, y_train)
```

[32]:
```
DecisionTreeRegressor(criterion='mse', max_depth=None, max_features=None,
                      max_leaf_nodes=None, min_impurity_decrease=0.0,
                      min_impurity_split=None, min_samples_leaf=1,
                      min_samples_split=2, min_weight_fraction_leaf=0.0,
                      presort=False, random_state=None, splitter='best')
```

Проверим метрики построенной модели:

[33]:
```
test_model(dt_none)
```

```
mean_absolute_error: 50.31291483113069
median_absolute_error: 0.7249999999999659
r2_score: 0.8297706825392527
```

Видно, что данный метод также без настройки гиперпараметров показывает приличный результат.

2.9.1. Случайный лес

Попробуем случайный лес с гиперпараметром $n = 100$:

[34]:
```
ran_100 = RandomForestRegressor(n_estimators=100)
ran_100.fit(X_train, y_train)
```

[34]:
```
RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
                      max_features='auto', max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, n_estimators=100,
                      n_jobs=None, oob_score=False, random_state=None,
                      verbose=0, warm_start=False)
```

Проверим метрики построенной модели:

[35]:
```
test_model(ran_100)
```

```
mean_absolute_error: 37.503140332843856
median_absolute_error: 0.5816499999999999
r2_score: 0.917512922249891
```

Видно, что данный метод даже без настройки гиперпараметров показывает очень хороший результат.

2.10. Подбор гиперпараметров

[36]:
```
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import ShuffleSplit
```

2.10.1. Метод k ближайших соседей

Введем список настраиваемых параметров:

[37]:
```
param_range = np.arange(1, 50, 2)
tuned_parameters = [{'n_neighbors': param_range}]
tuned_parameters
```

[37]:
```
[{'n_neighbors': array([ 1,  3,  5,  7,  9, 11, 13, 15, 17, 19, 21, 23, 25, 27,
29, 31, 33,
       35, 37, 39, 41, 43, 45, 47, 49])}]
```

Запустим подбор параметра:

[38]:
```
gs = GridSearchCV(KNeighborsRegressor(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

[38]:
```
KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
                    metric_params=None, n_jobs=None, n_neighbors=7, p=2,
                    weights='uniform')
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

[39]:
```
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

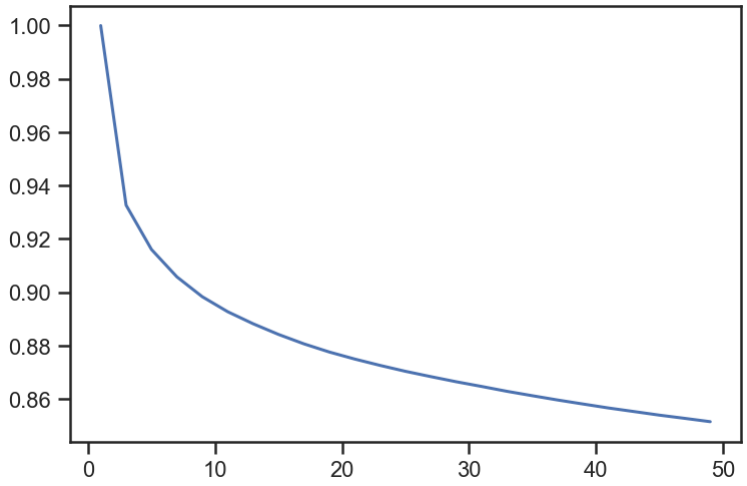

В целом результат ожидаемый — чем больше обученных моделей, тем лучше.
На тестовом наборе данных картина похожа:

[40]:
```
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

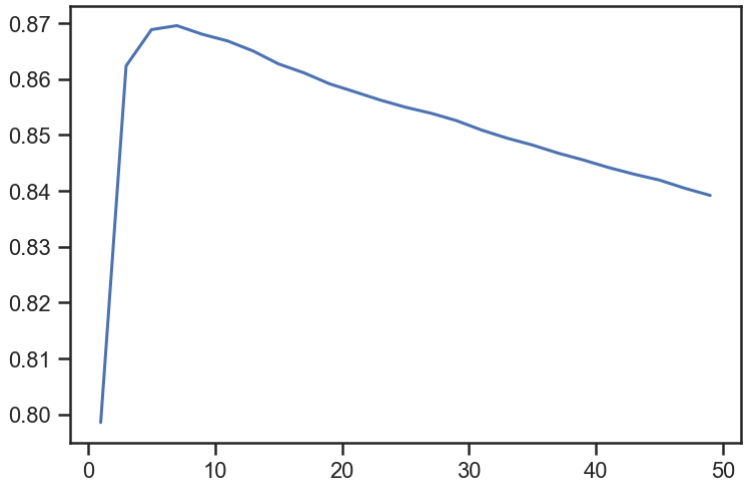

Видно, что наилучший результат достигается при $k = 7$.

[41]:
```
reg = gs.best_estimator_
reg.fit(X_train, y_train)
test_model(reg)
```

```
mean_absolute_error: 56.07154831829942
median_absolute_error: 4.7735714285714295
r2_score: 0.8687906728428422
```

Сравним с исходной моделью:

[42]:
```
test_model(knn_5)
```

```
mean_absolute_error: 55.39857905041605
median_absolute_error: 4.017000000000004
r2_score: 0.8677873476991447
```

Здесь получили чуть-чуть больший коэффициент детерминации, но незначительно просели по остальным показателям. Так что делаем вывод, что коэффициент детерминации сам по себе не является идеальной метрикой, и даёт лишь общее представление о качестве модели.

2.10.2. Дерево решений

Введем список настраиваемых параметров:

[43]:
```
param_range = np.arange(1, 50, 2)
tuned_parameters = [{'max_depth': param_range}]
tuned_parameters
```

[43]:
```
[{'max_depth': array([ 1,  3,  5,  7,  9, 11, 13, 15, 17, 19, 21, 23, 25, 27,
29, 31, 33,
       35, 37, 39, 41, 43, 45, 47, 49])}]
```

Запустим подбор параметра:

[44]:
```
gs = GridSearchCV(DecisionTreeRegressor(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

[44]:
```
DecisionTreeRegressor(criterion='mse', max_depth=11, max_features=None,
                      max_leaf_nodes=None, min_impurity_decrease=0.0,
                      min_impurity_split=None, min_samples_leaf=1,
                      min_samples_split=2, min_weight_fraction_leaf=0.0,
                      presort=False, random_state=None, splitter='best')
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

[45]:
```
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

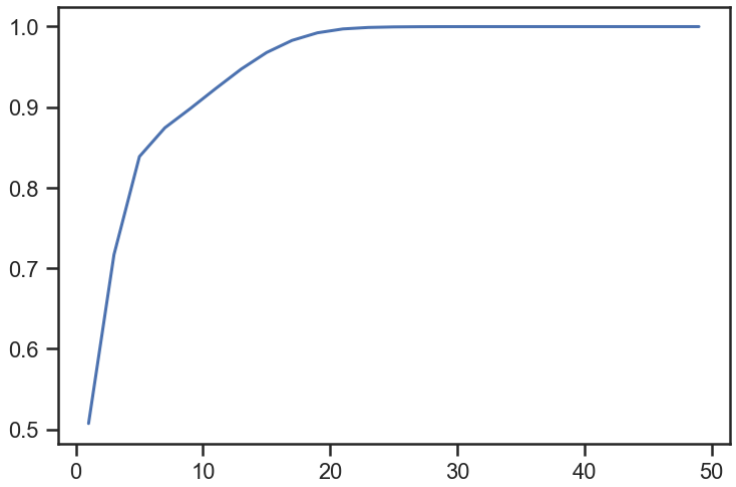

В целом результат ожидаемый — чем больше обученных моделей, тем лучше.

На тестовом наборе данных картина похожа:

[46]:
```
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

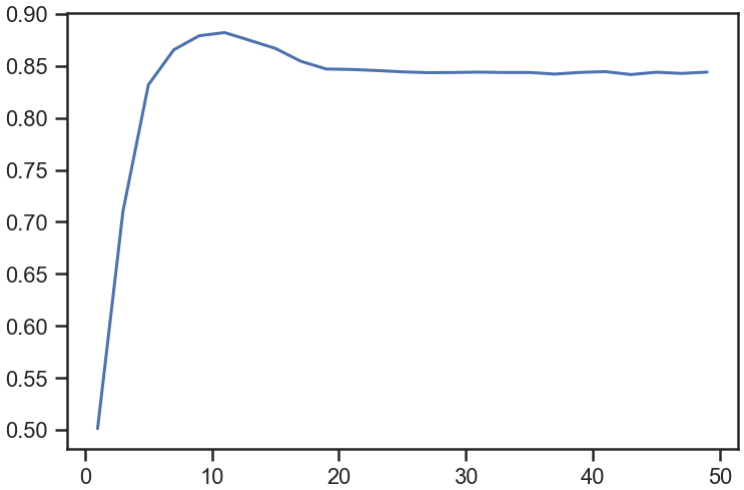

На графике чётко видно, что модель сначала работает хорошо, а потом начинает переобучаться на тренировочной выборке.

[47]:
```
reg = gs.best_estimator_
reg.fit(X_train, y_train)
test_model(reg)
```

```
mean_absolute_error: 48.51672010318737
median_absolute_error: 0.8996284533171739
r2_score: 0.8698555775877016
```

Сравним с исходной моделью:

[48]:
```
test_model(dt_none)
```

```
mean_absolute_error: 50.31291483113069
median_absolute_error: 0.7249999999999659
r2_score: 0.8297706825392527
```

Конкретно данная модель оказалась немного лучше, чем исходная.

2.10.3. Случайный лес

Введем список настраиваемых параметров:

[49]:
```
param_range = np.arange(20, 201, 20)
tuned_parameters = [{'n_estimators': param_range}]
tuned_parameters
```

[49]:
```
[{'n_estimators': array([ 20,  40,  60,  80, 100, 120, 140, 160, 180, 200])}]
```

Запустим подбор параметра:

[50]:
```
gs = GridSearchCV(RandomForestRegressor(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

[50]:
```
RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
                      max_features='auto', max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, n_estimators=160,
                      n_jobs=None, oob_score=False, random_state=None,
                      verbose=0, warm_start=False)
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

[51]:
```
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

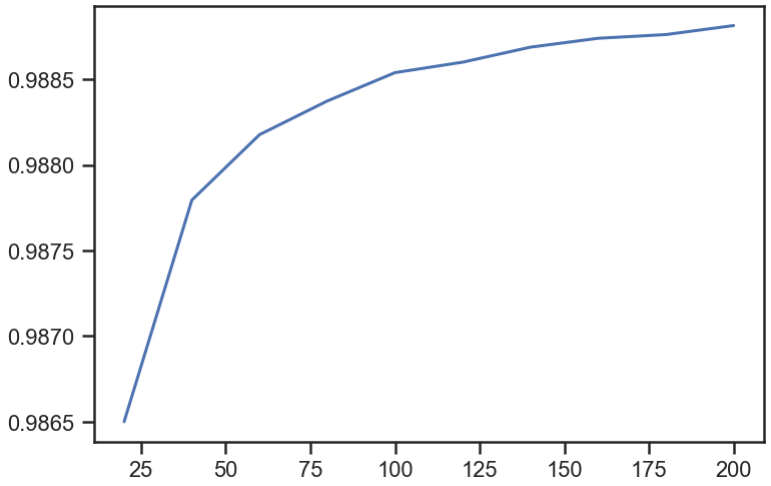

В целом результат ожидаемый — чем больше обученных моделей, тем лучше.

На тестовом наборе данных картина похожа:

[52]:
```
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

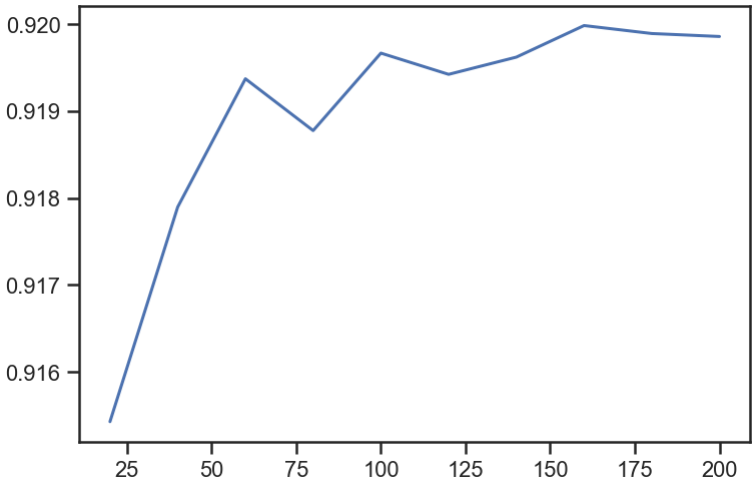

Из-за случайнойсти график немного плавает, но в целом получился чётко выраженный пик с наилучшим результатом.

[53]:
```
reg = gs.best_estimator_
reg.fit(X_train, y_train)
test_model(reg)
```

```
mean_absolute_error: 37.83773731185756
median_absolute_error: 0.6211875000000019
r2_score: 0.916153539481388
```

Сравним с исходной моделью:

[54]:
```
test_model(ran_100)
```

```
mean_absolute_error: 37.503140332843856
median_absolute_error: 0.5816499999999999
r2_score: 0.917512922249891
```

Данная модель также оказалась лишь немного лучше, чем исходная.

3. Выводы

Все построенные модели обладают очень хорошими показателями. Ансамблевая модель при этом обладает наилучшими характеристиками. Таким образом для дальнейшей работы стоит использовать именно ее.

Список литературы

[1] Гапанюк Ю. Е. Домашнее задание по дисциплине «Методы машинного обучения» [Электронный ресурс] // GitHub. — 2019. — Режим доступа: https://github.com/ugapanyuk/ml_course/wiki/MMO_DZ (дата обращения: 06.05.2019).

[2] You are my Sunshine [Electronic resource] // Space Apps Challenge. — 2017. — Access mode: https://2017.spaceappschallenge.org/challenges/earth-and-us/you-are-my-sunshine/details (online; accessed: 22.02.2019).

[3] dronio. Solar Radiation Prediction [Electronic resource] // Kaggle. — 2017. — Access mode: https://www.kaggle.com/dronio/SolarEnergy (online; accessed: 18.02.2019).

[4] Team The IPython Development. IPython 7.3.0 Documentation [Electronic resource] // Read the Docs. — 2019. — Access mode: https://ipython.readthedocs.io/en/stable/ (online; accessed: 20.02.2019).

[5] Waskom M. seaborn 0.9.0 documentation [Electronic resource] // PyData. — 2018. — Access mode: https://seaborn.pydata.org/ (online; accessed: 20.02.2019).

[6] pandas 0.24.1 documentation [Electronic resource] // PyData. — 2019. — Access mode: http://pandas.pydata.org/pandas-docs/stable/ (online; accessed: 20.02.2019).

[7] Chrétien M. Convert datetime.time to seconds [Electronic resource] // Stack Overflow. — 2017. — Access mode: https://stackoverflow.com/a/44823381 (online; accessed: 20.02.2019).