Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа №1
по дисциплине
«Методы машинного обучения»
на тему
«Разведочный анализ данных. Исследование и визуализация данных»

Выполнил:
студент группы ИУ5-22М
Смирнов А. И.

_____

Москва — 2019 г.

1. Цель лабораторной работы

Изучить различные методы визуализации данных [1].

2. Задание

Требуется выполнить следующие действия [1]:

- Выбрать набор данных (датасет).
- Создать ноутбук, который содержит следующие разделы:
  1. Текстовое описание выбранного набора данных.
  2. Основные характеристики датасета.
  3. Визуальное исследование датасета.
  4. Информация о корреляции признаков.
- Сформировать отчет и разместить его в своем репозитории на GitHub.

3. Ход выполнения работы

3.1. Текстовое описание набора данных

В качестве набора данных используются метрологические данные с метеостанции HI-SEAS (Hawaii Space Exploration Analog and Simulation) за четыре месяца (с сентября по декабрь 2016 года) [2]. Данный набор данных доступен по следующему адресу: https://www.kaggle.com/dronio/SolarEnergy. [3, 4]

Этот набор данных состоит из одного файла SolarPrediction.csv, содержащего все данные датасета. Данный файл содержит следующие колонки: [4, 5]

- UNIXTime — временная метка измерения в формате UNIX;
- Data — дата измерения;
- Time — время измерения (в местной временной зоне);
- Radiation — солнечное излучение ($Вт/м^2$);
- Temperature — температура (°F);
- Pressure — атмосферное давление (дюймов ртутного столба);
- Humidity — относительная влажность (%);
- WindDirection(Degrees) — направление ветра (°);
- Speed — скорость ветра (миль/ч);
- TimeSunRise — время восхода (в местной временной зоне);
- TimeSunSet — время заката (в местной временной зоне).

[1]:
```
from datetime import datetime
import pandas as pd
import seaborn as sns
```

[2]:
```
# Enable inline plots
%matplotlib inline

# Set plot style
sns.set(style="ticks")
```

```
# Set plots formats to save high resolution PNG
from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")
```

[3]:
```
pd.set_option("display.width", 70)
```

[4]:
```
data = pd.read_csv("./SolarPrediction.csv")
```

[5]:
```
data["UNIXTime"] = (pd
                    .to_datetime(data["UNIXTime"], unit="s", utc=True)
                    .dt.tz_convert("Pacific/Honolulu"))

data["Data"] = data["UNIXTime"].dt.date
data["Time"] = data["UNIXTime"].dt.time

data["TimeSunRise"] = (pd
                       .to_datetime(data["TimeSunRise"],
                                    infer_datetime_format=True)
                       .dt.time)

data["TimeSunSet"] = (pd
                      .to_datetime(data["TimeSunSet"],
                                   infer_datetime_format=True)
                      .dt.time)

data = data.rename({"Data": "Date",
                    "WindDirection(Degrees)": "WindDirection"},
                   axis=1)
```

[6]:
```
data.dtypes
```

[6]:
```
UNIXTime        datetime64[ns, Pacific/Honolulu]
Date                                      object
Time                                      object
Radiation                                float64
Temperature                                int64
Pressure                                 float64
Humidity                                   int64
WindDirection                            float64
Speed                                    float64
TimeSunRise                               object
TimeSunSet                                object
dtype: object
```

[7]:
```
data.head()
```

[7]:

	UNIXTime	Date	Time	Radiation
0	2016-09-29 23:55:26-10:00	2016-09-29	23:55:26	1.21
1	2016-09-29 23:50:23-10:00	2016-09-29	23:50:23	1.21
2	2016-09-29 23:45:26-10:00	2016-09-29	23:45:26	1.23
3	2016-09-29 23:40:21-10:00	2016-09-29	23:40:21	1.21
4	2016-09-29 23:35:24-10:00	2016-09-29	23:35:24	1.17

```
   Temperature  Pressure  Humidity  WindDirection  Speed  \
0           48     30.46        59         177.39   5.62
1           48     30.46        58         176.78   3.37
2           48     30.46        57         158.75   3.37
3           48     30.46        60         137.71   3.37
4           48     30.46        62         104.95   5.62

  TimeSunRise TimeSunSet
0    06:13:00   18:13:00
1    06:13:00   18:13:00
2    06:13:00   18:13:00
3    06:13:00   18:13:00
4    06:13:00   18:13:00
```

[8]:
```
def time_to_second(t):
    return ((datetime.combine(datetime.min, t) - datetime.min)
            .total_seconds())
```

[9]:
```
df = data.copy()

df["Day"] = df["UNIXTime"].dt.dayofyear

df["TimeInSeconds"] = df["Time"].map(time_to_second)

sunrise = df["TimeSunRise"].map(time_to_second)
sunset = df["TimeSunSet"].map(time_to_second)
df["DayPart"] = (df["TimeInSeconds"] - sunrise) / (sunset - sunrise)

df = df.drop(["UNIXTime", "Date", "Time",
              "TimeSunRise", "TimeSunSet"], axis=1)

df.head()
```

[9]:
```
   Radiation  Temperature  Pressure  Humidity  WindDirection  Speed  \
0       1.21           48     30.46        59         177.39   5.62
1       1.21           48     30.46        58         176.78   3.37
2       1.23           48     30.46        57         158.75   3.37
3       1.21           48     30.46        60         137.71   3.37
4       1.17           48     30.46        62         104.95   5.62

   Day  TimeInSeconds   DayPart
0  273        86126.0  1.475602
1  273        85823.0  1.468588
2  273        85526.0  1.461713
3  273        85221.0  1.454653
4  273        84924.0  1.447778
```

[10]:
```
df.dtypes
```

[10]:
```
Radiation        float64
Temperature        int64
Pressure         float64
Humidity           int64
WindDirection    float64
Speed            float64
Day                int64
TimeInSeconds    float64
DayPart          float64
dtype: object
```

[11]:
```
df.shape
```

[11]:
```
(32686, 9)
```

[12]:
```
df.describe()
```

[12]:

	Radiation	Temperature	Pressure	Humidity
count	32686.000000	32686.000000	32686.000000	32686.000000
mean	207.124697	51.103255	30.422879	75.016307
std	315.916387	6.201157	0.054673	25.990219
min	1.110000	34.000000	30.190000	8.000000
25%	1.230000	46.000000	30.400000	56.000000
50%	2.660000	50.000000	30.430000	85.000000
75%	354.235000	55.000000	30.460000	97.000000
max	1601.260000	71.000000	30.560000	103.000000

	WindDirection	Speed	Day	TimeInSeconds
count	32686.000000	32686.000000	32686.000000	32686.000000
mean	143.489821	6.243869	306.110965	43277.574068
std	83.167500	3.490474	34.781367	24900.749819
min	0.090000	0.000000	245.000000	1.000000
25%	82.227500	3.370000	277.000000	21617.000000
50%	147.700000	5.620000	306.000000	43230.000000
75%	179.310000	7.870000	334.000000	64849.000000
max	359.950000	40.500000	366.000000	86185.000000

	DayPart
count	32686.000000
mean	0.482959
std	0.602432
min	-0.634602
25%	-0.040139
50%	0.484332
75%	1.006038
max	1.566061

[13]:
```
sns.distplot(df["Radiation"]);
```

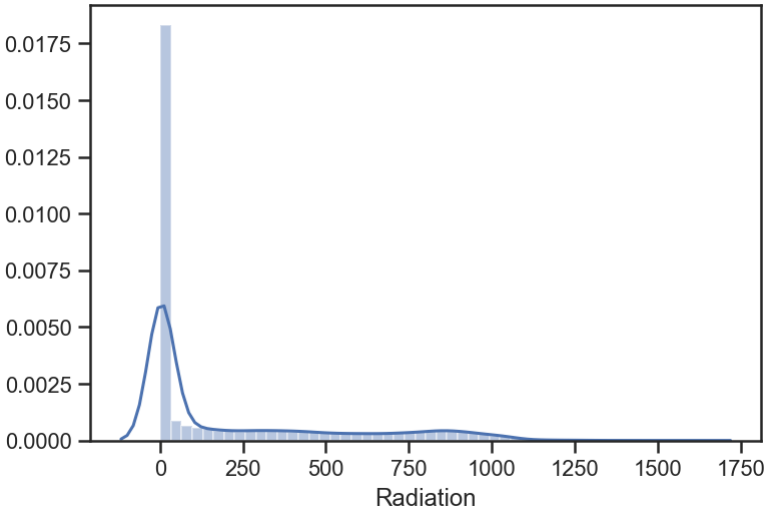

[14]:
```
sns.jointplot(x="DayPart", y="Radiation", data=df, kind="hex");
```

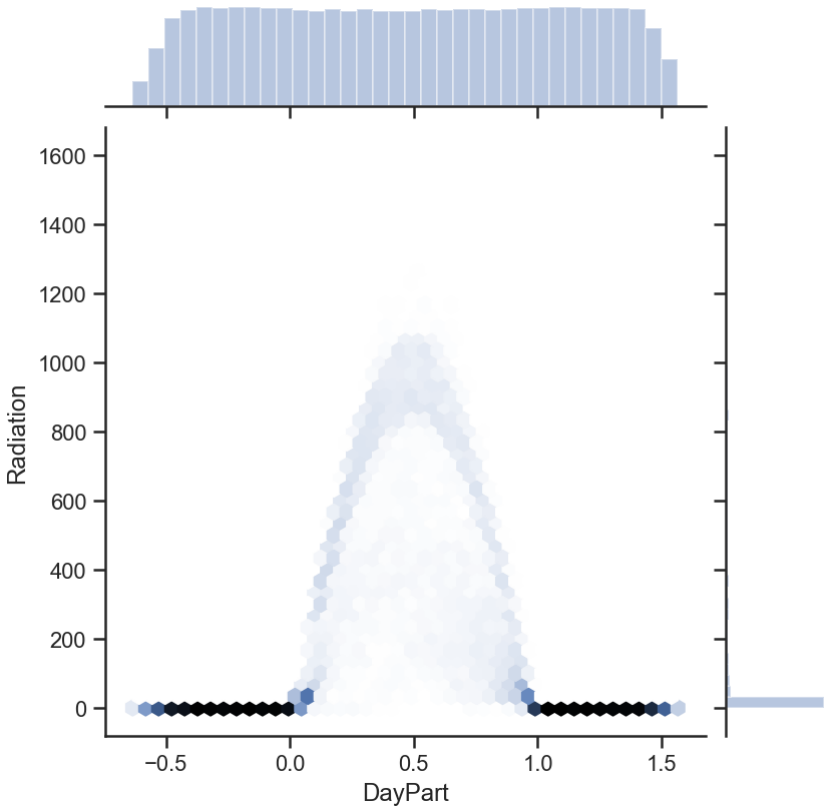

[15]:
```
dfd = df[(df["DayPart"] >= 0) & (df["DayPart"] <= 1)]
sns.distplot(dfd["Radiation"]);
```

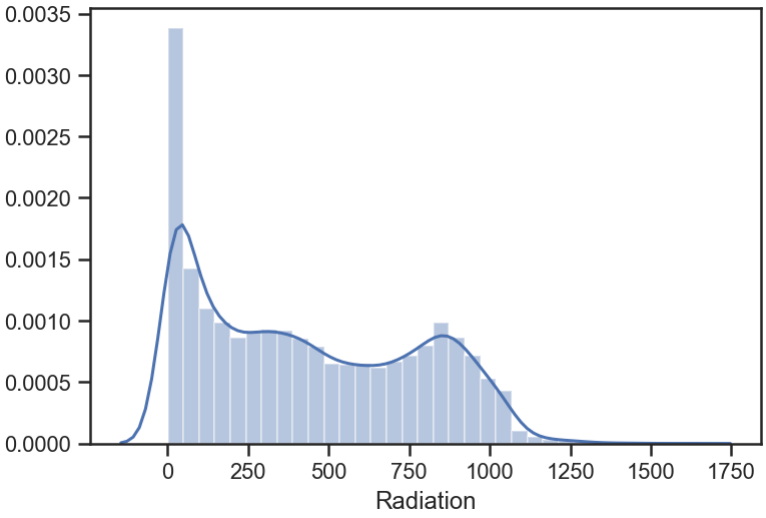

[16]:
```
sns.jointplot(x="DayPart", y="Radiation", data=dfd, kind="hex");
```

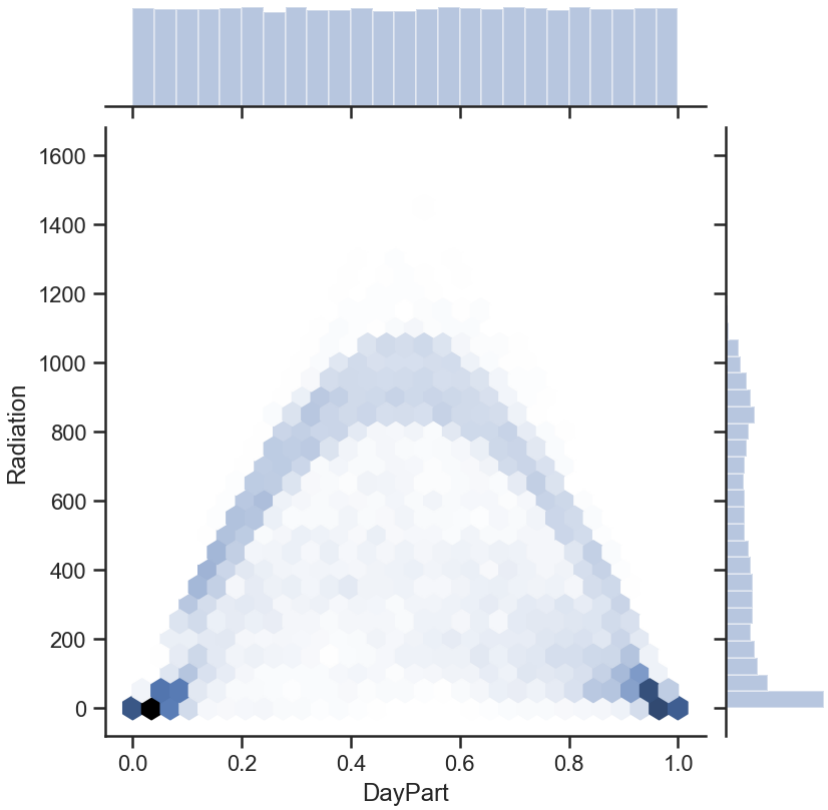

[17]:
```
sns.jointplot(x="Temperature", y="Radiation", data=dfd, kind="kde");
```

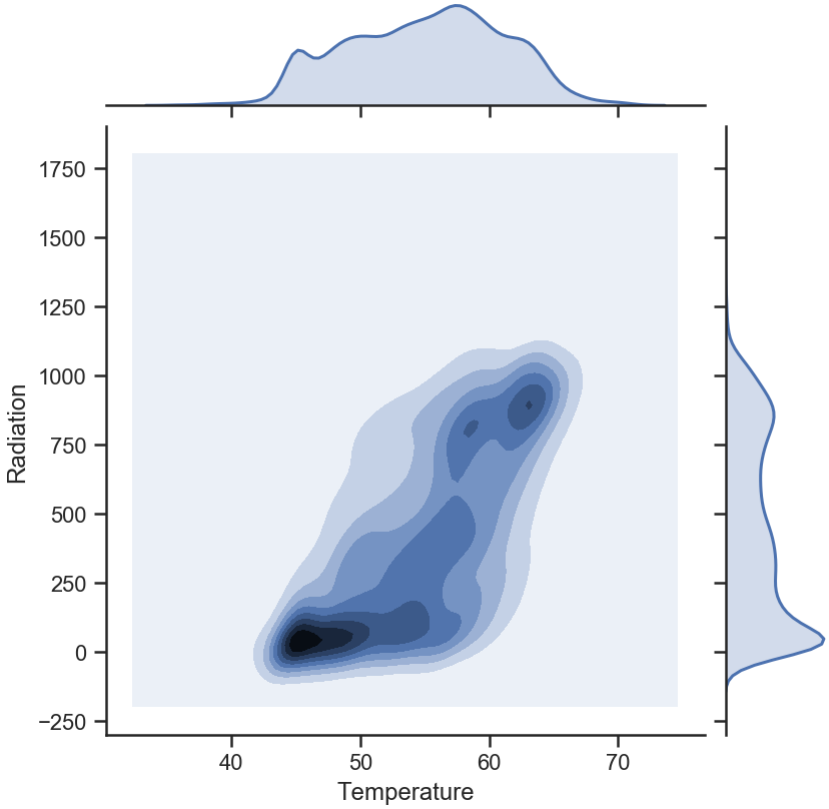

[18]:
```
sns.pairplot(df, plot_kws=dict(linewidth=0));
```

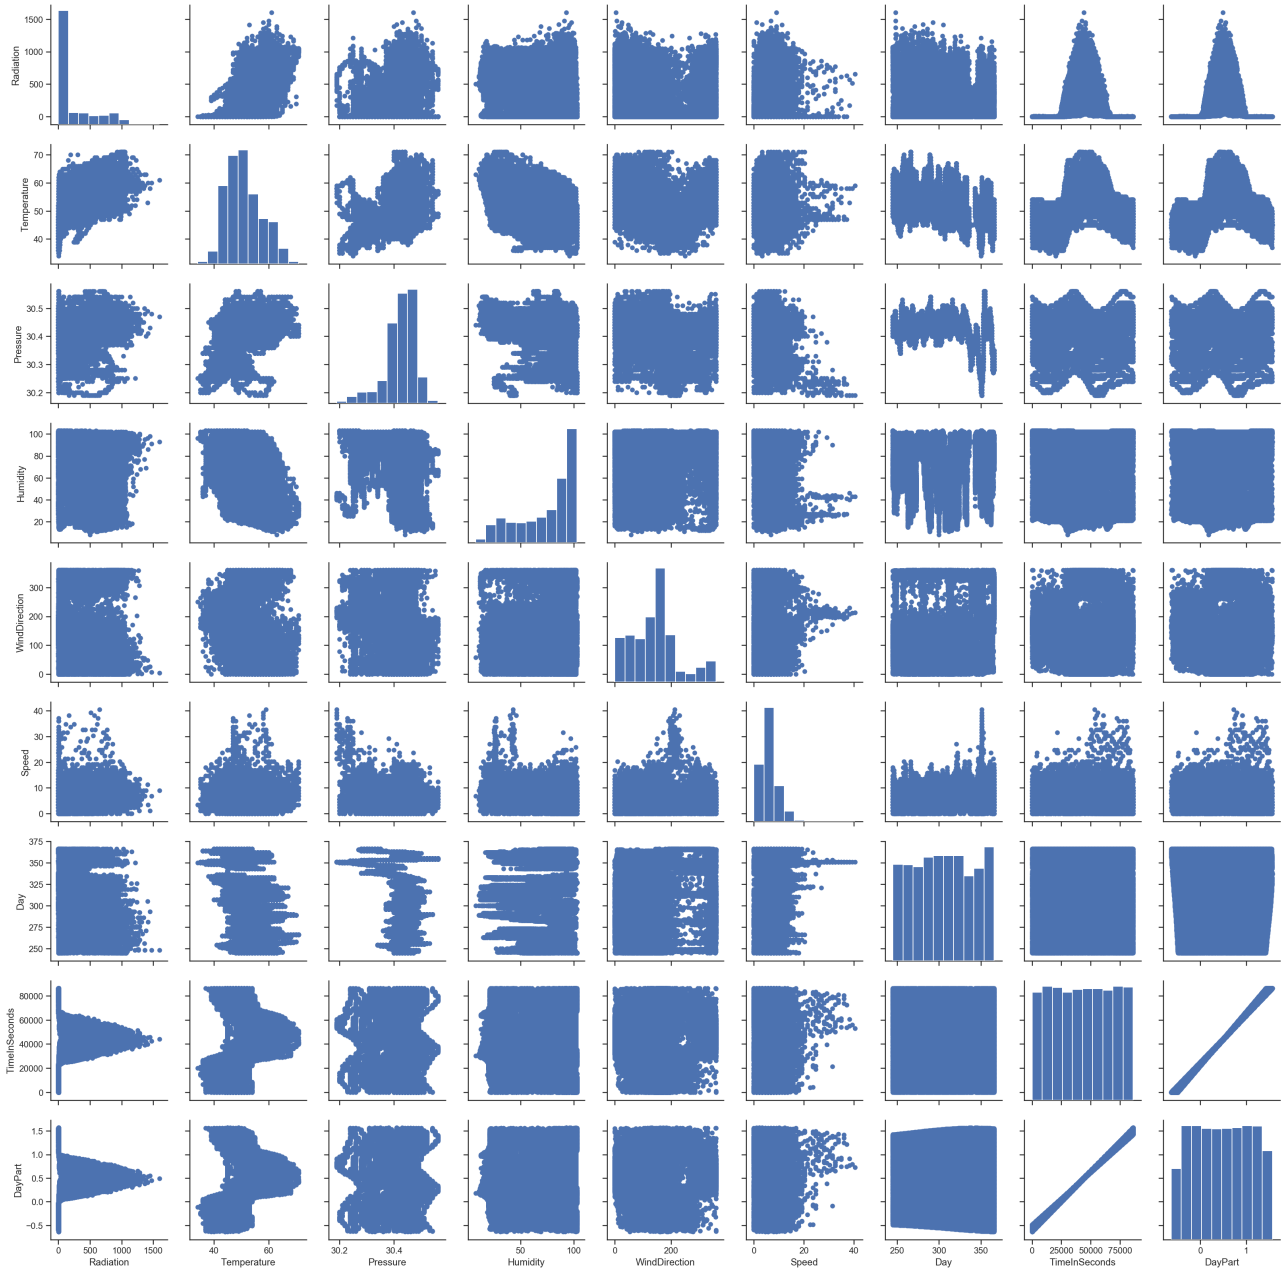

[19]:
```
df.corr()
```

[19]:
```
                Radiation  Temperature  Pressure  Humidity  \
Radiation        1.000000     0.734955  0.119016 -0.226171
Temperature      0.734955     1.000000  0.311173 -0.285055
Pressure         0.119016     0.311173  1.000000 -0.223973
Humidity        -0.226171    -0.285055 -0.223973  1.000000
WindDirection   -0.230324    -0.259421 -0.229010 -0.001833
Speed            0.073627    -0.031458 -0.083639 -0.211624
Day             -0.081320    -0.370794 -0.332762 -0.063760
TimeInSeconds    0.004348     0.197227  0.091066  0.077851
DayPart          0.005980     0.198520  0.094403  0.075513

                WindDirection     Speed       Day  TimeInSeconds  \
```

```
Radiation          -0.230324  0.073627 -0.081320       0.004348
Temperature        -0.259421 -0.031458 -0.370794       0.197227
Pressure           -0.229010 -0.083639 -0.332762       0.091066
Humidity           -0.001833 -0.211624 -0.063760       0.077851
WindDirection       1.000000  0.073092  0.153255      -0.077956
Speed               0.073092  1.000000  0.174336      -0.057908
Day                 0.153255  0.174336  1.000000      -0.007094
TimeInSeconds      -0.077956 -0.057908 -0.007094       1.000000
DayPart            -0.078130 -0.056095 -0.010052       0.998980
```

```
                DayPart
Radiation      0.005980
Temperature    0.198520
Pressure       0.094403
Humidity       0.075513
WindDirection -0.078130
Speed         -0.056095
Day           -0.010052
TimeInSeconds  0.998980
DayPart        1.000000
```

[20]:
```
sns.heatmap(df.corr(), annot=True, fmt=".2f");
```

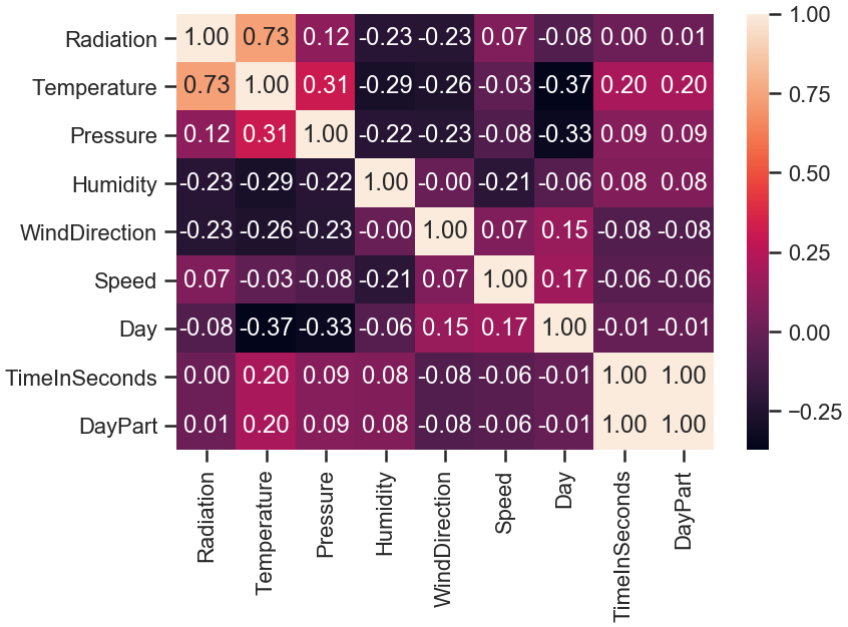

Список литературы

[1] Гапанюк Ю. Е. Лабораторная работа «Разведочный анализ данных. Исследование и визуализация данных» [Электронный ресурс] // GitHub. — 2019. — Режим доступа: https://github.com/ugapanyuk/ml_course/wiki/LAB_EDA_VISUALIZATION (дата обращения: 13.02.2019).

[2] dronio. Solar Radiation Prediction [Electronic resource] // Kaggle. — 2017. — Access mode: https://www.kaggle.com/dronio/SolarEnergy (online; accessed: 18.02.2019).

[3] Team The IPython Development. IPython 7.3.0 Documentation [Electronic resource] // Read the Docs. — 2019. — Access mode: https://ipython.readthedocs.io/en/stable/ (online; accessed: 20.02.2019).

[4] Waskom M. seaborn 0.9.0 documentation [Electronic resource] // PyData. — 2018. — Access mode: https://seaborn.pydata.org/ (online; accessed: 20.02.2019).

[5] pandas 0.24.1 documentation [Electronic resource] // PyData. — 2019. — Access mode: http://pandas.pydata.org/pandas-docs/stable/ (online; accessed: 20.02.2019).